

Classificação de Qualidade de Vinhos com Machine Learning

POSTECH Data Analytics — Tech Challenge 2

Fase 2 Gráficos, Métricas e Interpretação dos

Modelos

Objetivo

Desenvolver modelos de Machine Learning capazes de prever se um vinho é de **Alta Qualidade** (nota ≥ 7) ou **Baixa/Média Qualidade** (nota < 7) com base em suas características físico-químicas, substituindo ou auxiliando a avaliação subjetiva por especialistas.

Dataset: Wine Quality Dataset (Kaggle) | 1.143 amostras | 11 features físico-químicas

1. Balanceamento das Classes

O dataset apresenta **desbalanceamento significativo**: cerca de 86% das amostras são de baixa/média qualidade e apenas 14% de alta qualidade. Essa característica influencia diretamente a escolha das métricas e estratégias de modelagem.




Figura 1 — Distribuição original das notas (esq.) e variável binária criada (dir.)

Estratégia adotada: uso de `class_weight="balanced"` nos modelos e priorização de métricas como F1-Score e ROC-AUC no lugar da simples acurácia.

2. Análise de Correlação

A análise de correlação revela quais variáveis estão mais associadas à qualidade do vinho. Variáveis com correlação positiva tendem a elevar a nota; negativas, a reduzi-la.




Figura 2 — Correlação de cada feature com a variável alvo (qualidade binária)

Feature	Correlacao	Interpretacao
alcohol	+0.48	Vinhos de alta qualidade tendem a ter maior teor alcoólico
volatile acidity	-0.39	Acidez volátil elevada indica defeitos fermentativos
sulphates	+0.27	Sulfatos atuam como conservantes e melhoram a qualidade
citric acid	+0.23	Ácido cítrico contribui para frescor e complexidade
density	-0.21	Densidade maior associada a vinhos de qualidade inferior




Figura 3 — Matriz de correlação completa entre todas as variáveis

3. Modelos Treinados

Foram treinados três modelos de classificação, com divisão estratificada 80/20 (treino/teste) e

Modelo	Tipo	Parâmetros Principais
Regressão Logística	Linear	max_iter=1000, class_weight=balanced
Random Forest	Ensemble (bagging)	n_estimators=200, max_depth=10, class_weight=balanced
Gradient Boosting	Ensemble (boosting)	n_estimators=200, max_depth=4, learning_rate=0.05

class_weight="balanced" para lidar com o desbalanceamento.

4. Métricas de Avaliação

Os modelos foram avaliados com cinco métricas complementares. O **Gradient Boosting** obteve o melhor F1-Score (0,689) e o **Random Forest** o melhor ROC-AUC (0,901), indicando excelente capacidade discriminativa.

Modelo	Acurácia	Precisão	Recall	F1-Score	ROC-AUC
Regressão Log.	79,0%	36,2%	65,6%	0,467	0,863
Random Forest	90,8%	72,0%	56,2%	0,632	0,901
Gradient Boost	91,7%	72,4%	65,6%	0,689	0,887

Tabela 1 — Métricas no conjunto de teste (20% das amostras). Linha destacada = melhor modelo geral.




Figura 4 — Comparação visual das métricas por modelo

Nota sobre as métricas: Em problemas desbalanceados, a *acurácia* pode ser enganosa. O **F1-Score** equilibra precisão e recall, sendo mais adequado. O **ROC-AUC** mede a capacidade de separar as classes independentemente do threshold.

5. Curvas ROC

As curvas ROC mostram o trade-off entre sensibilidade e especificidade para cada modelo. Quanto mais próximo do canto superior esquerdo, melhor o modelo.




Figura 5 — Curvas ROC com área sob a curva (AUC) para cada modelo

6. Matrizes de Confusão

As matrizes de confusão revelam como cada modelo erra. Para o negócio, **falsos negativos** (vinho bom classificado como ruim) são especialmente importantes — o modelo pode rejeitar produções de alta qualidade incorretamente.




Figura 6 — Matrizes de confusão dos três modelos (conjunto de teste)

Modelo	Verdadeiros Positivos	Falsos Negativos	Observação
Reg. Logística	21 / 32	11	Melhor recall — menos vinhos bons perdidos
Random Forest	18 / 32	14	Melhor precisão — menos falsos alarmes
Gradient Boosting	21 / 32	11	Melhor equilíbrio geral

7. Importância das Features

A importância das features indica quais variáveis mais contribuem para as decisões do modelo. Os dois modelos baseados em ensemble concordam nas principais features.




Figura 7 — Importância relativa das features (Random Forest e Gradient Boosting)

Ranking	Feature	Importancia (GB)	Significado Pratico
1	alcohol	~0.28	Teor alcoólico — principal preditor de qualidade
2	volatile acidity	~0.15	Acidez volátil — defeito fermentativo (vinagre)
3	sulphates	~0.10	Sulfatos — conservante e potencializado de aromar
4	citric acid	~0.08	Ácido cítrico — frescor e estabilidade
5	density	~0.07	Densidade — relacionada ao teor alcoólico e de açúcar

8. Conclusões e Recomendações

Melhor modelo recomendado: Gradient Boosting

O Gradient Boosting apresentou o melhor equilíbrio entre precisão e recall ($F1=0,689$) com ROC-AUC de 0,887 — excelente capacidade de discriminar vinhos de alta e baixa qualidade. O Random Forest é igualmente competitivo (ROC-AUC=0,901) e pode ser preferido quando a interpretabilidade e velocidade de inferência são prioritárias.

Implicações para o processo produtivo:

#	Acao	Impacto Esperado
1	Monitorar e otimizar o teor alcoólico (alcohol)	Maior correlação com alta qualidade — controlar fermentação
2	Controlar a acidez volátil (volatile acidity)	Evitar defeitos fermentativos que reduzem a nota
3	Ajustar dosagem de sulfatos (sulphates)	Melhora conservação e perfil aromático
4	Usar o modelo como triagem automática	Redução de custos com análise sensorial humana
5	Reavaliação periódica do modelo	Garantir performance com novos lotes de produção